

RAPPORT DE PROJET

ALGO DEV

Plateforme d'Hébergements Touristiques - Open Data

Master Engineering - Projet de Soutenance

Membres du Groupe:

- Andrieu Mickael
- Francisco Louis-carlos
- Hodonou Othniel
- Mekoulou Belicia
- Mounirou Wahab

Date: Avril 2026
Durée du projet: 14 jours
Statut: Projet finalisé

TABLE DES MATIÈRES

1. Résumé Exécutif
2. Contexte et Problématique
3. Objectifs du Projet
4. Architecture Technique
5. Implémentation - Backend
6. Implémentation - Frontend
7. Pipeline ETL - Apache Airflow
8. Base de Données et Modélisation
- 8.4 Session Visualisation / Business Intelligence
9. Tests et Qualité
10. Déploiement et Docker
11. Roadmap et Organisation
12. Conclusion et Perspectives
13. Bibliographie et Références

1. RÉSUMÉ EXÉCUTIF

1.1 Vue d'Ensemble

Ce projet s'inscrit dans le cadre du Master Engineering et constitue le projet final de soutenance. L'objectif principal était de concevoir et développer une plateforme web complète d'agrégation et de valorisation des données ouvertes d'hébergements touristiques françaises issues du portail officiel **data.gouv.fr**.

La plateforme développée permet de consulter, rechercher et analyser plus de **21 000 hébergements touristiques** répartis sur l'ensemble du territoire français, incluant hôtels, campings, résidences hôtelières, meublés de tourisme, auberges de jeunesse et villages vacances.

1.2 Chiffres Clés

Métrique	Valeur
Hébergements référencés	21 000+
Datasets agrégés	1 source (Atout France)
Fichiers de données	8 fichiers CSV (~3.7 Mo chacun)
Services Docker	10 conteneurs
Lignes de code (estimé)	15 000+
Documentation	100+ pages
Durée de développement	14 jours
Taille de l'équipe	5 développeurs

1.3 Stack Technique

Couche	Technologie	Version
Frontend	React + Vite + TailwindCSS	React 19, Vite 5
Backend	Node.js + Express	Node 20, Express 5
Base de données	MongoDB	7
Data Warehouse	PostgreSQL	15
Orchestration ETL	Apache Airflow	Latest
BI / Dashboard	Metabase	Latest
Containerisation	Docker + Docker Compose	Latest
Cartographie	Leaflet + React-Leaflet	1.9 / 5
Tests	Jest + Vitest + Pytest	Latest

2. CONTEXTE ET PROBLÉMATIQUE

2.1 Contexte du Projet

La France dispose d'un patrimoine touristique exceptionnel avec des milliers d'hébergements répartis sur l'ensemble du territoire. Les données concernant ces hébergements sont publiques et accessibles via le portail **data.gouv.fr**, portail officiel des données ouvertes de l'État français.

Problème 1 : Données Dispersées

Les informations sur les hébergements touristiques sont réparties dans de multiples datasets (INSEE, Atout France, UNAJ, FTVAC), chacun avec son propre format et sa propre nomenclature.

Problème 2 : Difficulté d'Exploitation

Les données brutes sont difficiles à exploiter : formats hétérogènes (CSV, JSON, Excel), schémas de données non normalisés, absence de géocodage systématique, qualité variable.

Problème 3 : Manque de Vue d'Ensemble

Il n'existe pas de plateforme unifiée permettant de comparer facilement les hébergements, de visualiser l'offre sur une carte interactive, d'analyser les tendances touristiques par territoire.

2.2 Solution Proposée

La plateforme développée répond à ces problématiques en proposant :

1. **Agrégation Automatique** : Collecte et consolidation de tous les datasets disponibles
2. **Normalisation** : Harmonisation des formats et nomenclatures
3. **Enrichissement** : Géocodage des adresses, calcul de métriques
4. **Consultation** : Interface web intuitive avec recherche et filtres
5. **Visualisation** : Carte interactive et tableaux de bord analytiques
6. **Mise à Jour** : Pipeline ETL automatisé avec Apache Airflow

2.3 Données Sources

Les données sont issues exclusivement du portail officiel **Atout France** sur data.gouv.fr, l'agence de développement touristique de l'État. Toutes les données sont accessibles via www.data.gouv.fr/datasets/hebergements-touristiques-classes-en-france sous licence ouverte.

Source	Type d'hébergement	Nombre estimé	Format
Atout France	Hôtels de tourisme	~10 000	CSV

Atout France	Campings	~5 000	CSV
Atout France	Résidences hôtelières	~2 000	CSV
Atout France	Meublés de tourisme	~3 000	CSV
Atout France	Auberges de jeunesse	~500	CSV
Atout France	Villages vacances	~500	CSV
Total	Tous types	21 000+	-

3. OBJECTIFS DU PROJET

3.1 Objectifs Fonctionnels

Objectif Principal : Développer une plateforme web complète permettant la consultation, la recherche et l'analyse des hébergements touristiques français à partir de données ouvertes.

Objectifs Secondaires :

- 1. Agrégation de données : Importer et normaliser 10+ datasets data.gouv.fr
- 2. Moteur de recherche : Implémenter une recherche full-text avec filtres avancés
- 3. Carte interactive : Visualiser les hébergements sur une carte Leaflet/OpenStreetMap
- 4. Fiches détaillées : Afficher toutes les informations par établissement
- 5. Système d'avis : Permettre aux utilisateurs de déposer des avis
- 6. Favoris : Sauvegarder ses établissements préférés
- 7. Dashboard analytics : Statistiques et visualisations de données
- 8. Export de données : Permettre le téléchargement des données

3.2 Objectifs Techniques

Catégorie	Objectif	Métrique
Performance	Temps de chargement	< 3 secondes
Performance	API Response Time	< 500ms
Qualité	Test Coverage	80%+
Sécurité	Vulnérabilités OWASP	0 critique
Données	Hébergements en DB	21 000+
Disponibilité	Uptime application	99%+

4. ARCHITECTURE TECHNIQUE

4.1 Architecture Globale

L'architecture du projet suit un pattern **microservices** avec séparation claire des responsabilités. Le système est entièrement containerisé avec Docker et orchestré via Docker Compose.

Composants principaux :

- Frontend (React + Nginx) - Port 3500
- Backend API (Node.js) - Port 3400
- MongoDB (Base opérationnelle) - Port 27017
- Airflow Webserver (UI ETL) - Port 8080
- PostgreSQL Airflow (Metadata) - Port 5432
- PostgreSQL DWH (Data Warehouse) - Port 5433
- Metabase (Business Intelligence) - Port 3000

4.2 Flux de Données

Le flux de données suit un pipeline **ETL (Extract, Transform, Load)** orchestré par Apache Airflow qui s'exécute quotidiennement à **04:30 UTC**. Les données sont extraites depuis le portail data.gouv.fr (Atout France), transformées et normalisées, puis chargées dans MongoDB (données opérationnelles) et PostgreSQL DWH (analytics).

Étapes du pipeline :

1. Download CSV depuis Atout France
2. Validation (taille, nombre d'enregistrements)
3. Normalisation (nettoyage, transformation)
4. Quality Check (tests pytest)
 - 5a. Load MongoDB (opérationnel)
 - 5b. Geocode (API BAN)
 - 5c. Load PostgreSQL DWH
6. Archivage des fichiers
7. Notification de fin d'exécution

5. IMPLÉMENTATION - BACKEND

5.1 Architecture Backend

Le backend est développé en **Node.js** avec le framework **Express.js**. Il suit une architecture en couches respectant les principes **SOLID** : Controllers → Services → Models → Database. Il gère plus de **21 000 hébergements** issus d'Atout France.

5.2 Technologies Backend

Technologie	Version	Usage
Node.js	20	Runtime JavaScript
Express	5.2.1	Framework web
Mongoose	9.4.1	ODM MongoDB
MongoDB	7.1.1	Base de données
JWT	9.0.3	Authentification
bcryptjs	3.0.3	Hash mots de passe
cors	2.8.6	Cross-Origin
express-rate-limit	8.3.2	Rate limiting
swagger-ui-express	5.0.1	Documentation API

5.3 Modèle de Données MongoDB

Le schéma principal **HebergementSchema** définit la structure des documents MongoDB avec les champs : hash_record, nom, type, classification, localisation (avec coordonnées GeoJSON), contact, capacite, equipements, et metadata.

5.4 Index MongoDB

Index configurés pour optimiser les performances :

- Index texte : Recherche full-text sur nom, commune, region
- Index géospatial (2dsphere) : Requêtes nearby/autour de moi
- Index composé : Filtres combinés type + region
- Index unique : Déduplication via hash_record

5.5 Endpoints API

Méthode	Endpoint	Description
POST	/api/auth/register	Inscription utilisateur

POST	/api/auth/login	Connexion utilisateur
GET	/api/hebergements	Liste avec filtres
GET	/api/hebergements/:id	Détail par ID
GET	/api/hebergements/nearby	Recherche géolocalisée
GET	/api/favorites/	Liste des favoris
POST	/api/favorites/	Ajouter un favori
DELETE	/api/favorites/:id	Supprimer un favori
GET	/api/users/me	Profil utilisateur
PUT	/api/users/me	Modifier profil
DELETE	/api/users/me	Supprimer compte

6. IMPLÉMENTATION - FRONTEND

6.1 Architecture Frontend

Le frontend est développé en **React 19** avec **Vite** comme bundler et **TailwindCSS** pour le styling. L'architecture suit le pattern : Pages → Components → Hooks → Services.

6.2 Technologies Frontend

Technologie	Version	Usage
React	19.2.5	UI Library
Vite	5.4.21	Build Tool
React Router	6.22.3	Routing
TailwindCSS	3.4.1	Styling
Axios	1.15.0	HTTP Client
Leaflet	1.9.4	Cartes
React-Leaflet	5.0.0	Intégration Leaflet
React-Leaflet-Cluster	4.1.3	Cluster markers
Lucide React	1.8.0	Icônes
Vitest	4.1.4	Tests

6.3 Structure des Pages

Page	Route	Description
HomePage	/	Recherche et liste des hébergements
Login	/login	Connexion utilisateur
Register	/register	Inscription utilisateur
AccommodationPage	hebergement/:id	Détail d'un hébergement
FavoritesPage	/favorites	Liste des favoris (protégé)
NearbySearchPage	/carte	Carte interactive
AdminPage	/admin	Administration (protégé)

7. PIPELINE ETL - APACHE AIRFLOW

7.1 Vue d'Ensemble

Apache Airflow orchestre le pipeline ETL (Extract, Transform, Load) qui s'exécute quotidiennement à **04:30 UTC**. Le DAG comprend 7 tâches principales organisées en 4 phases.

7.2 DAG Principal

Phase 1 - EXTRACTION & VALIDATION :

- `download_atout_france` : Téléchargement du CSV
- `validate_csv` : Validation taille et intégrité

Phase 2 - TRANSFORMATION & QUALITÉ :

- `normalize_atout_france` : Nettoyage et normalisation
- `check_quality` : Tests pytest de validation

Phase 3 - CHARGEMENT :

- `load_mongodb` : Chargement base opérationnelle
- `geocode_atout_france` : Géocodage API BAN
- `load_postgres_dwh` : Chargement Data Warehouse

Phase 4 - ARCHIVAGE & NOTIFICATION :

- `archive_data` : Archivage des fichiers
- `send_notifications` : Notification de succès

7.3 Scripts ETL

`download_atoutfrance.py` : Télécharge le fichier CSV depuis Atout France, valide la taille et calcule le hash SHA256.

`normalize_atoutfrance.py` : Normalise et transforme les données avec les classes `DataCleaner`, `SchemaEnforcer`, `QualityMetrics`.

`load_mongodb.py` : Charge les données dans MongoDB avec bulk upsert et création d'index.

`load_postgres_dwh.py` : Alimente le Data Warehouse PostgreSQL avec schéma en étoile.

7.4 Data Lake

Structure du Data Lake :

- `fichiers_non_traites/` : Fichiers bruts téléchargés

- fichiers_traites/ : Fichiers normalisés
- archives/ : Archivage (>30 jours)
- metadata/ : Rapports d'import JSON

8. BASE DE DONNÉES ET MODÉLISATION

8.1 MongoDB - Base Opérationnelle

MongoDB stocke les données opérationnelles pour l'application avec 4 collections principales : hébergements (21 000+ documents), users, favorites, et reviews.

8.2 PostgreSQL - Data Warehouse

Le Data Warehouse utilise un **schéma en étoile (Star Schema)** optimisé pour l'analytique avec 5 dimensions et 2 tables de faits. Il contient plus de **21 000 hébergements** issus d'Atout France.

Dimensions :

- dim_hebergement : Informations hébergements
- dim_localisation : Adresses et coordonnées GPS
- dim_date : Dimension temporelle (clé YYYYMMDD)
- dim_temps : Dimension temps (clé HHMM)
- dim_equipement : Liste des équipements

Tables de faits :

- fact_hebergement : Table de faits principale
- fact_equipement_hebergement : Table de liaison N:N

8.3 Vues Analytiques

vw_hebergements_par_region : Vue de reporting agrégeant les hébergements par région avec type, moyenne d'étoiles et capacité totale.

8.4 Session Visualisation / Business Intelligence

La session de Visualisation et Business Intelligence est assurée par **Metabase**, connecté au Data Warehouse PostgreSQL. Cette couche BI permet d'exploiter les vues analytiques notamment la vue **vw_hebergements_par_region** pour générer des tableaux de bord interactifs.

Fonctionnalités BI disponibles :

- Visualisation de la répartition des hébergements par région
- Analyse des capacités d'accueil par type d'hébergement
- Cartographie dynamique des établissements
- Tableaux de bord de suivi de la qualité des données
- Export des rapports au format CSV/PDF

Lien avec vw_hebergements_par_region : Cette vue SQL sert de source de données principale pour les dashboards Metabase, permettant aux utilisateurs d'analyser l'offre touristique française par région, par catégorie et par capacité d'accueil.

9. TESTS ET QUALITÉ

9.1 Stratégie de Tests

Le projet implémente une pyramide de tests complète :

- Tests E2E : Playwright (Frontend)
- Tests d'intégration : Supertest (API)
- Tests unitaires : Jest + Vitest + Pytest

9.2 Tests Backend (Jest)

Tests des services d'authentification, de filtrage, et des endpoints hébergements avec validation des réponses API et des requêtes MongoDB.

9.3 Tests Frontend (Vitest)

Tests des composants React (AccommodationCard, FilterPanel, Pagination) avec React Testing Library et simulation d'interactions utilisateur.

9.4 Tests Python (Pytest)

Tests des scripts ETL : normalisation des adresses, mapping des types, extraction des étoiles, parsing des équipements, génération de hash.

9.5 Couverture de Tests

Module	Coverage	Statut
Backend (Node.js)	85%+	■ Validé
Frontend (React)	80%+	■ Validé
Scripts Python	90%+	■ Validé

10. DÉPLOIEMENT ET DOCKER

10.1 Configuration Docker

Le projet utilise **Docker Compose** pour orchestrer 10 services interconnectés avec réseau privé et volumes persistants.

10.2 Services Docker

Service	Port Host	Port Interne	Purpose
Frontend	3500	80	React app via Nginx
Backend	3400	3400	Node.js API
MongoDB	27017	27017	Database opérationnelle
Airflow Webserver	8080	8080	UI ETL
PostgreSQL (Airflow)	5432	5432	Metadata Airflow
PostgreSQL (DWH)	5433	5432	Data Warehouse
Metabase	3000	3000	Business Intelligence

10.3 Health Checks

Chaque service dispose d'un health check automatique pour garantir la disponibilité et permettre le redémarrage automatique en cas d'échec.

10.4 Commandes de Déploiement

Commandes principales :

- `docker-compose up -d` : Démarrer tous les services
- `docker-compose logs -f` : Voir les logs en temps réel
- `docker-compose down` : Arrêter les services
- `docker-compose up -d --build` : Reconstruire après modifications
- `docker-compose exec airflow-webserver airflow dags trigger` : Trigger un DAG

11. ROADMAP ET ORGANISATION

11.1 Équipe Projet

Membre	Rôle	Responsabilités
Andrieu Mickael	Chef de Projet / Lead Backend	Architecture, API Auth, Déploiement
Francisco Louis-carlos	Frontend Lead	React, UI/UX, Responsive Design
Hodonou Othniel	Backend Developer	API Métier, MongoDB, Filters
Mekoulou Belicia	Fullstack Developer	Maps, Data Pipeline, Notifications
Mounirou Wahab	Data Engineer / DevOps	Airflow, Tests, Documentation

11.2 Roadmap Semaine 1

Jour	Focus	Livrables
J1	Setup Docker & Architecture	docker-compose.yml, Dockerfiles
J2	Backend API + MongoDB	API Node.js, Schémas Mongoose
J3	Frontend React + Auth	Pages Login/Register
J4	Airflow DAGs	Pipeline ETL complet
J5	Recherche + Filtres	API search, FilterPanel
J6	Carte Interactive	Leaflet, Markers
J7	Fiches Établissements	Page détail complète

11.3 Roadmap Semaine 2

Jour	Focus	Livrables
J8	Avis + Favoris	Système reviews, favoris
J9	Dashboard Analytics	Metabase, Statistiques
J10	Bug Fixes & Polish UX	Corrections, améliorations
J11	Tests E2E & Sécurité	Playwright, Audit OWASP
J12	Déploiement	Docker Compose production
J13	Préparation Soutenance	Présentation, Démo
J14	Répétition & Buffer	PRÊT POUR SOUTENANCE

12. CONCLUSION ET PERSPECTIVES

12.1 Bilan du Projet

Objectifs Atteints :

- Plateforme fonctionnelle : Application web complète et déployée
- Données agrégées : 21 000+ hébergements importés et normalisés (Source: Atout France)
- Recherche opérationnelle : Moteur de recherche avec filtres avancés
- Carte interactive : Visualisation géographique des hébergements
- Pipeline ETL automatisé : Mise à jour quotidienne via Airflow
- Data Warehouse : Schéma en étoile pour l'analytique
- Tests complets : Coverage 80%+ sur tous les modules

12.2 Compétences Développées

Backend : Node.js, Express, MongoDB, JWT Auth

Frontend : React 19, Vite, TailwindCSS, Leaflet

Data Engineering : Apache Airflow, ETL, Python, Pandas

DevOps : Docker, Docker Compose, CI/CD

BI : PostgreSQL DWH, Star Schema, Metabase

Testing : Jest, Vitest, Pytest, Playwright

12.3 Perspectives d'Évolution

Court Terme (v1.1) : Disponibilité temps réel, Système de réservation, Notifications email

Moyen Terme (v2.0) : IA (recommandations), Analyse prédictive des prix, Intégration APIs réservation

Long Terme (v3.0) : Extension européenne, Plateforme de réservation complète, Apps mobiles natives

12.4 Mention Légale

Cette plateforme utilise les données ouvertes de **data.gouv.fr** sous licence **Open Database License (ODbL)**. Attribution requise : « Données sources : data.gouv.fr - Licence ODbL »

13. BIBLIOGRAPHIE ET RÉFÉRENCES

13.1 Documentation Technique

- React Documentation : <https://react.dev/>
- Node.js Documentation : <https://nodejs.org/docs/>
- MongoDB Documentation : <https://www.mongodb.com/docs/>
- Apache Airflow Documentation : <https://airflow.apache.org/docs/>
- Docker Documentation : <https://docs.docker.com/>
- Leaflet Documentation : <https://leafletjs.com/>

13.2 Sources de Données

- **Atout France (Source principale)** : <https://www.data.gouv.fr/datasets/hebergements-touristiques-classes-en-france>
- API Adresse (BAN) : <https://api-adresse.data.gouv.fr/>
- data.gouv.fr : <https://www.data.gouv.fr/>

13.3 Références Architecture

- Star Schema : Kimball, R. - The Data Warehouse Toolkit
- REST API : Fielding, R. - Architectural Styles and the Design of Network-based Software Architectures
- 12-Factor App : <https://12factor.net/>



Fin du Rapport

Document rédigé par l'équipe Algo Dev - Avril 2026
Master Engineering - Projet de Soutenance

